中階三 B10805025 沈睿朋

目錄

題目 2
第一題 2
第二題 3
進行數據分類 3
設定訓練集與測試集 3
決策數分析 3
SVM(支持向量機) 3
羅吉斯回歸 4
總結 4

■ 題目

1. 以 H/R, W/E, 1Q, 2Q, 3Q, 3P, TOT, OR, DR, A, ST, TO 等因子，分析哪些因子為影響球隊勝負重要的特徵？
2. 以上述影響球隊勝負重要的特徵作為預測變數，利用不同的機器學習方法建立球隊勝負之預測模式，並說明分析所得之主要結果。

第一題

#使用變異數分析&卡方檢定，檢測 H/R, W/E, 1Q, 2Q, 3Q, 3P, TOT, OR, DR, A, ST, TO 中那些對「勝負」有顯著影響

變異數分析

	F_value	p-value	是否顯著
TOT	178.698113	2.140753e-39	顯著影響
DR	330.869590	1.828317e-69	顯著影響
OR	4.348504	3.714440e-02	顯著影響
1Q	156.986161	5.887485e-35	顯著影響
2Q	155.138091	1.411436e-34	顯著影響
3Q	185.237739	1.002774e-40	顯著影響
3P	196.725606	4.726052e-43	顯著影響
A	271.757649	5.427676e-58	顯著影響
ST	50.604077	1.476007e-12	顯著影響
TO	32.063278	1.665941e-08	顯著影響

卡方檢定

	chi	p-value	是否顯著
H/R	68.333333	1.380673e-16	顯著影響
W/E	2.733333	9.827398e-02	無顯著影響

從上兩張圖可得出只有 W/E 對「勝負」沒有顯著影響

因 P 值大於 0.05 的關係

第二題

- 進行數據分類

➢ 自變數 X

```
X = data[["TOT","DR","OR","1Q","2Q","3Q","3P","A","ST","TO","H/R"]]
```

➢ 依變數 y

```
y = data['W/L']
```

- 設定訓練集與測試集

```
X_train, X_test,y_train,y_test = train_test_split(X,y,test_size=0.2,random_state=5)
```

決策數分析

利用 sklearn 函式庫的決策樹(tree)訓練模型，並且分支最高層數 max_depth=5

訓練模型的結果主要看的是測試集資料，訓練集資料相較不重要

➢ 混淆矩陣

訓練集結果

```
[[707 279]
 [219 763]]
=====================================================

              precision    recall  f1-score   support

           0       0.76      0.72      0.74       986
           1       0.73      0.78      0.75       982

    accuracy                           0.75      1968
   macro avg       0.75      0.75      0.75      1968
weighted avg       0.75      0.75      0.75      1968
```

測試集結果

```
[[163  81]
 [ 46 202]]
=====================================================

              precision    recall  f1-score   support

           0       0.78      0.67      0.72       244
           1       0.71      0.81      0.76       248

    accuracy                           0.74       492
   macro avg       0.75      0.74      0.74       492
weighted avg       0.75      0.74      0.74       492
```

SVM(支持向量機)

利用 sklearn 函式庫的 SVM(svm)訓練模型

➢ 混淆矩陣

訓練集結果

```
[[750 236]
 [220 762]]
=====================================================

              precision    recall  f1-score   support

           0       0.77      0.76      0.77       986
           1       0.76      0.78      0.77       982

    accuracy                           0.77      1968
   macro avg       0.77      0.77      0.77      1968
weighted avg       0.77      0.77      0.77      1968
```

測試集結果

```
[[177  67]
 [ 54 194]]
=====================================================

              precision    recall  f1-score   support

           0       0.77      0.73      0.75       244
           1       0.74      0.78      0.76       248

    accuracy                           0.75       492
   macro avg       0.75      0.75      0.75       492
weighted avg       0.75      0.75      0.75       492
```

羅吉斯回歸

利用 sklearn 函式庫的羅吉斯回歸(LogisticRegression)訓練模型

- 找尋切割值

  利用切割值 p_value 決定目標變數的類別

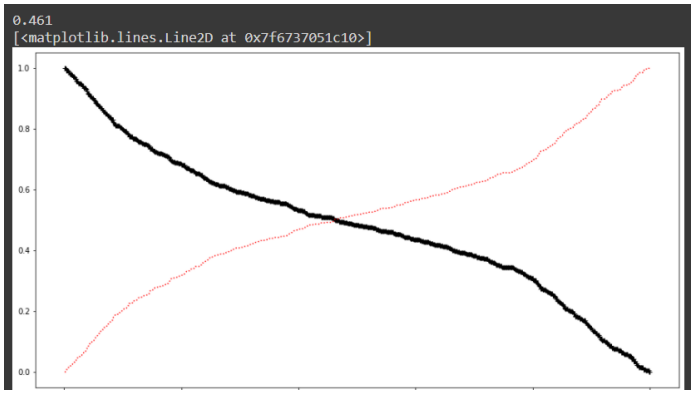

切割值為 0.461

- 以切割值調整精準度,p 為切割值，取得預測結果

  p = 0.461

  pre_t=pre_test_prob[0].apply(lambda x: 0 if x>p else 1)

- 得出混淆矩陣

```
[[185  59]
 [ 63 185]]
              precision    recall  f1-score   support

           0       0.75      0.76      0.75       244
           1       0.76      0.75      0.75       248

    accuracy                           0.75       492
   macro avg       0.75      0.75      0.75       492
weighted avg       0.75      0.75      0.75       492
```

總結

- 可發現到決策數分析、SVM、羅吉斯回歸的混淆矩陣
  測試與訓練集的精確度都只有 0.7 多且 f1 的準確度也是一樣 0.7 多
  可看出此模型沒有良好的效果但也沒有太差。

備註

模式衡量指標數據參考:

	真實為真	真實為假
預測為真	tp	fp
預測為假	fn	tn

- **準確率（Accuracy）** = (tp+tn)/(tp+fp+fn+tn)
  「預測」與「判斷」皆完全正確的。
- **精確率（Precision）** = tp/(tp+fp)
  「模型預測」為真(TP+FP)，而「真實資料」為真的比率，即陽性的樣本中有幾個是預測正確的。
- **召回率（Recall）** = tp/(tp+fn)
  「真實資料」為真(TP+FN)，而「模型預測」為真的比率，即事實為真的樣本中有幾個是預測正確的。
- **F1** = 2 / ((1/ Precision) + (1/ Recall))，
  即精確率與召回率的調和平均數，可看作是該二指標的綜合指標。
- **support（支持）**:表示的是在這個類別中真實樣本的數量
- **Avg:**顯示的是對應指標的加權平均（按每個類別中的樣本個數加權）。
- **Macro-average**:該方法最簡單，直接將不同類別的評估指標（Precision/ Recall/ F1-score）加起來求平均(算術平均值)，給所有類別相同的權重。能夠平等看待每個類別，但是它的值會受稀有類別影響。
- **Weighted-average**:該方法給不同類別不同權重(權重根據該類別的真實分佈比例確定），每個類別乘權重後再進行相加。該方法考慮了類別不平衡情況，它的值更容易受到常見類（majority class）的影響。

➢ *average 參數有五種：None, 'micro', 'macro', 'weighted', 'samples'*
這裡使用了 'macro' 以及 'weighted' 兩種 avg 參數

資料來源: https://ithelp.ithome.com.tw/articles/10228941?sc=rss.qu

資料來源: https://zhuanlan.zhihu.com/p/147663370